CentraleSupélec x CEA DAM

Rapport Projet ST7

OPTIMISATION D'ITINERAIRE SOUS CONTRAINTES DE SECURITE ET DE RISQUE.

Réalisé par le groupe no.2
Noé Kaynak
Paul Ourliac
Liora Madar
Bao Lugherini
Adam Kodja
Paul Ménard

5 avril 2026

Table des matières

1 Introduction **1**
1.1 Contexte et enjeux . . . 1
1.2 La pression comme critère de destruction . . . 1
1.3 Une limitation majeure : le temps de calcul . . . 2
1.4 Cahier des charges . . . 2

2 Modélisation mathématique **3**
2.1 Définition du problème . . . 3
2.2 Représentation du graphe . . . 4

3 Développement d'une solution numérique **5**
3.1 Architecture de la chaîne de traitement . . . 5
3.2 Choix des algorithmes . . . 6
3.2.1 Plus court chemin . . . 6
3.2.2 k-dominating set . . . 7
3.2.3 Modélisation par Processus Gaussiens de la fonction coût . . . 8
3.3 Optimisation du temps de calcul . . . 10
3.3.1 Parallélisation . . . 10
3.3.2 Étude de sensibilité au maillage : choix du pas de simulation . . . 10
3.4 Scalabilité . . . 12

4 Résultats et validation **13**
4.1 Simulations . . . 13
4.2 Résultat final : chemin de coût minimal obtenu . . . 14
4.2.1 Problème initial : Mauvaise détection topologique par EGO . . . 15
4.2.2 Résolution et résultat final ($\alpha = 1,5$) . . . 15

5 Perspectives **17**
5.1 Améliorations possibles . . . 17
5.2 Extensions envisageables . . . 17

6 Conclusion **18**

Annexes **18**

7 Annexe 1 – Fondements mathématiques de l'optimisation bayésienne **19**
7.1 Processus Gaussiens et Krigeage . . . 19
7.1.1 Modèle probabiliste . . . 19
7.1.2 Prédiction par Krigeage Ordinaire . . . 19
7.1.3 Estimation des hyperparamètres . . . 20
7.2 Critère d'amélioration espérée (Expected Improvement) . . . 20
7.2.1 Motivation . . . 20
7.2.2 Définition et formule analytique . . . 20
7.3 Algorithme EGO (*Efficient Global Optimization*) . . . 21
7.4 Extension au critère multipoints (q-EI) . . . 21
7.5 Application au projet : synthèse de la chaîne de traitement . . . 21
7.6 Validation sur fonctions tests analytiques . . . 22
7.6.1 Cas test 2D : fonction à oscillations couplées . . . 22
7.6.2 Protocole expérimental . . . 22

7.6.3 Résultats 22

8 Annexe 2 – Pseudo-code de l'algorithme d'enrichissement séquentiel 24

8.1 Algorithme principal 24

8.2 Complexité 25

Chapitre 1

Introduction

1.1 Contexte et enjeux

La découverte de vestiges d'engins explosifs impose l'adoption immédiate de mesures de prudence strictes, en particulier lorsque ces engins datent de la Seconde Guerre mondiale, leur vieillissement pouvant entraîner une instabilité accrue.

À l'origine, ce type d'obus contient une charge explosive (TNT, amatol ou mélanges nitratés) enfermée dans une enveloppe métallique et associée à un système d'amorçage (fusée). Après plus de 80 ans, plusieurs mécanismes physico-chimiques ont altéré ses propriétés initiales, dégradant fortement sa stabilité globale.

Le point le plus critique concerne la fusée. Avec le temps, ses composants internes (ressorts, percuteurs, dispositifs de retard) peuvent se corroder, se bloquer ou se fragiliser. Cela peut conduire à une situation particulièrement dangereuse : soit le mécanisme devient inopérant, soit au contraire il devient extrêmement sensible en raison de la dégradation des dispositifs de sécurité initiaux. Dans ce dernier cas, une simple vibration ou une faible contrainte mécanique peut suffire à déclencher une mise à feu.

Par ailleurs, la corrosion de l'enveloppe métallique fragilise la structure de l'obus. Elle peut engendrer des microfissures facilitant l'infiltration d'humidité et d'oxygène, ce qui accélère la dégradation des composés internes. Les explosifs eux-mêmes évoluent également avec le temps : le TNT peut exsuder (formation de cristaux en surface), tandis que d'autres composés peuvent se transformer en substances plus sensibles aux chocs et aux frottements.

D'un point de vue cinétique, la vitesse de réaction chimique suit une loi de type Arrhenius, augmentant exponentiellement avec la température. Le vieillissement des matériaux peut en outre abaisser l'énergie d'activation, rendant l'explosif plus réactif et imprévisible, même dans des conditions apparemment stables.

Afin de limiter ces risques lors du transport, les mesures suivantes doivent être impérativement respectées :

- Maintenir une température stable et aussi basse que possible, en évitant toute élévation thermique susceptible d'accélérer les réactions chimiques.
- Réduire au maximum les chocs et les vibrations, en manipulant l'obus avec une extrême précaution.
- Utiliser un dispositif de calage adapté (type nid d'amortissement) afin de limiter les contraintes mécaniques durant le transport.

Dans ce contexte, le Commissariat à l'énergie atomique et aux énergies alternatives (CEA) nous a confié l'étude du problème du déminage en milieu urbain. Cette problématique revêt une importance particulière, tant dans le cadre des dispositifs de sécurité tels que le plan Vigipirate que face à des situations concrètes récemment observées, notamment en Seine-Saint-Denis en mars 2025 ou plus récemment encore dans le centre de Paris, à proximité d'infrastructures sensibles. Par ailleurs, l'évolution du contexte géopolitique international, marquée notamment par les tensions au Moyen-Orient, laisse présager une augmentation de la fréquence de ce type d'interventions, renforçant ainsi la nécessité d'une approche rigoureuse et anticipative.

Comment trouver le meilleur chemin entre un point A et un point B afin de minimiser le risque en milieu urbain ?

1.2 La pression comme critère de destruction

L'explosion d'une bombe crée une onde de choc. Lorsque cette onde frappe le bâtiment, elle applique instantanément une force gigantesque (plusieurs tonnes par mètre carré) sur les façades. Ce qui détruit les bâtiments. Dans notre étude nous avons fixé un seuil de surpression de 140mBar. Ce choix s'appuie sur la réglementation française en matière de prévention des risques majeurs, et plus spécifiquement sur les critères d'évaluation

de l'intensité des effets d'une explosion définis par les textes officiels (notamment l'arrêté gouvernemental de référence).

1.3 Une limitation majeure : le temps de calcul

Dans un contexte opérationnel tel que le déminage en milieu urbain, la contrainte de temps de calcul est centrale. En effet, la découverte d'un engin explosif impose une mise en sécurité rapide afin de limiter l'exposition des populations et des infrastructures environnantes. L'algorithme développé ne doit donc pas seulement être précis, mais également capable de produire une solution exploitable dans un délai très court.

Cette contrainte introduit un compromis fondamental entre la qualité de la solution et son temps de calcul. Des méthodes très précises, reposant par exemple sur des modèles continus complexes ou des explorations exhaustives de l'espace des solutions, peuvent devenir inadaptées en pratique si leur temps d'exécution est trop élevé. À l'inverse, des approches plus simples et rapides permettent d'obtenir des trajectoires satisfaisantes en un temps compatible avec les exigences opérationnelles.

Par ailleurs, la contrainte économique joue également un rôle important. Les ressources de calcul disponibles sur le terrain peuvent être limitées, et il est nécessaire de privilégier des algorithmes peu coûteux en mémoire et en puissance de calcul.

Enfin, il convient de noter que nous disposons dans ce cadre des ressources de calcul du supercalculateur du CEA. Cette capacité permet d'envisager des traitements plus complexes et d'accélérer significativement les temps de calcul, notamment lors des phases de simulation ou d'optimisation. Elle offre ainsi la possibilité d'explorer un plus grand nombre de solutions ou d'affiner les modèles utilisés, tout en respectant les contraintes temporelles du problème. Néanmoins, même avec de telles ressources, il reste essentiel de concevoir des algorithmes efficaces afin de garantir leur robustesse et leur transférabilité vers des contextes opérationnels plus contraints. On se donne typiquement un temps de calcul de référence de l'ordre de 10 heures.

1.4 Cahier des charges

Le développement de l'outil de planification de trajectoire doit répondre aux exigences suivantes :

- **Flexibilité :** L'outil doit être capable de traiter différents scénarios (variation de la topologie, des points de départ et d'arrivée, et des catégories de bâtiments) via des paramètres en entrée.
- **Passage à l'échelle :** L'outil doit rester performant lorsque la taille du problème (nombre de nœuds, complexité de la carte) augmente.
- **Contraintes temporelles :** Une solution doit être calculée dans un délai maximal de 24 heures.
- **Optimisation du risque :** L'objectif principal est de minimiser le risque associé à la trajectoire, à travers une fonction de coût intégrant les impacts potentiels sur l'environnement urbain.
- **Optimisation des coûts :** Le modèle doit également prendre en compte et minimiser les coûts monétaires et environnementaux liés au transport.
- **Performance algorithmique :** Il est attendu de démontrer la pertinence du recours à la parallélisation afin de réduire les temps de calcul.
- **Robustesse du modèle :** Le modèle doit être fiable et sa précision doit être quantifiée à l'aide d'indicateurs pertinents.
- **Justification des choix :** Les hypothèses et choix de modélisation doivent être explicités et justifiés.
- **Documentation :** Le code produit doit être documenté afin d'en faciliter la compréhension, l'utilisation et la maintenance.

Chapitre 2

Modélisation mathématique

2.1 Définition du problème

On reformule le problème posé comme un problème d'optimisation sous contraintes.

Définitions :
- $\Omega \subset \mathbb{R}^n$: Espace de travail ($n = 2, 3$).
- $\mathcal{O} \subset \Omega$: Obstacles (bâtiments, zones sensibles).
- $\Omega_{\text{free}} = \Omega \setminus \mathcal{O}$: Espace de navigation.
- x_A, x_B : Points de départ et d'arrivée.
- $\mathcal{P}$: Espace des chemins admissibles pour notre solution, défini par :

$$\mathcal{P} = \left\{ \gamma \in \mathcal{C}^1([0,1], \Omega) \;\middle|\; \gamma(0) = x_A,\, \gamma(1) = x_B \right\}$$

Contrainte géométrique :
Pour qu'une solution soit admissible, elle doit rester dans l'espace de navigation :

$$\forall t \in [0,1], \quad \gamma(t) \in \Omega_{\text{free}}$$

Fonction de coût :

$$J(\gamma) = \int_0^1 \mathcal{R}(\gamma(t))\gamma'(t)dt + \int_0^1 \left[g\big(z'(t)\big) \right] dt$$

$$J(\gamma) = \int_\gamma \mathcal{R} + \int_0^1 \left[g\big(z'(t)\big) \right] dt$$

Où $\mathcal{R}$ est la fonction de risque en un point $x \in \Omega_{\text{free}}$, définie de la manière suivante :

$$\forall x \in \Omega_{\text{free}}, \quad \mathcal{R}(x) = \sum_{i \in \mathcal{B}} D_i \cdot f(K_i)$$

$\mathcal{B}$: Ensemble des bâtiments.
f : Fonction croissante positive selon l'importance socio-économique de chaque catégorie.
D_i : Taux de destruction du bâtiment i (à savoir taux surface du bâtiment exposée à un pression supérieure à la pression seuil), où $D_i \in [0,1]$.
K_i : Indice de catégorie du bâtiment i.
g : Fonction de pénalisation des variations d'altitude, choisie croissante en fonction de $|z'(t)|$ où z est l'altitude de la bombe. Une variation brusque cette dernière pourrait entrainer un plus grand risque d'explosion.

Problème d'optimisation :
On obtient alors le problème d'optimisation suivant :

$$\min_{\gamma \in \mathcal{P}} J(\gamma) \quad \text{tel que} \quad \forall t \in [0,1], \quad \gamma(t) \in \Omega_{\text{free}}$$

2.2 Représentation du graphe

Afin de rendre le problème traitable numériquement, l'espace de navigation Ω_{free} est discrétisé sous la forme d'un graphe $G = (V, E)$. Les nœuds V correspondent à un ensemble de points de l'espace obtenus par un maillage régulier, tandis que les arêtes E représentent les connexions possibles entre ces points.

Le maillage retenu est un maillage quadrillé auquel sont ajoutées les connexions diagonales, permettant d'améliorer la connectivité du graphe et d'obtenir des trajectoires plus naturelles. Cette modélisation limite notamment les changements brusques de direction et les sollicitations à haute fréquence du véhicule.

Chaque arête $(u, v) \in E$ est pondérée par un coût qui approxime la fonctionnelle continue définie précédemment. Ce coût intègre à la fois le risque associé à la traversée de l'espace et la pénalisation des variations d'altitude. Plus précisément, pour une arête reliant deux nœuds u et v, le poids est défini comme une approximation discrète de :

$$\int_u^v \left[\mathcal{R}(x) + g\big(z'(x)\big)\right] dx$$

Dans la pratique, cette intégrale est évaluée de manière approchée à partir d'une interpolation d'un petit nombre de valeurs de $\mathcal{R}$ et de la variation d'altitude entre les deux nœuds.

Enfin, les obstacles sont pris en compte en supprimant du graphe tous les nœuds situés dans $\mathcal{O}$ ou suffisamment proche de $\mathcal{O}$ ainsi que les arêtes les traversant. On obtient ainsi un graphe exploitable pour les algorithmes de plus court chemin, garantissant que toute trajectoire calculée reste dans l'espace de navigation autorisé.

Chapitre 3

Développement d'une solution numérique

3.1 Architecture de la chaîne de traitement

- **Construction du graphe de Ω_{free}**
  - Génération d'un maillage structuré 2D, incluant les connectivités diagonales, sur la carte de la ville.
  - Projection de ce graphe sur l'espace 3D : pondération des arêtes par les distances réelles.
  - Élagage des noeuds et arêtes en collision avec un bâtiment, incluant une zone tampon de sécurité de 0,5 m.
- **Initialisation du plan d'expérience (DoE)**
  - Sélection d'un échantillon initial de k nœuds via un algorithme de *farthest point sampling*. Cette approche maximise la distance inter-nœuds pour garantir une couverture spatiale exhaustive de Ω_{free} avant simulation (se référer à 3.2.2 pour plus de détails).
- **Simulation et caractérisation du risque**
  - Simulation numérique des champs de surpression générés par une explosion en chaque point du DoE.
  - Évaluation du coût scalaire associé à chaque nœud, représentant l'intégrale des dommages induits par l'explosion.
- **Modélisation par Processus Gaussiens**
  - Construction d'un métamodèle (Krigeage) pour l'interpolation de la surface de coût sur Ω_{free} (se référer à 3.2.3 pour plus de détails))
  - Boucle d'enrichissement séquentiel (EGO) :
    - Identification itérative des n zones présentant la variance de krigeage la plus élevée.
    - Exécution de simulations complémentaires et mise à jour récursive du prédicteur.
    - Critère d'arrêt : la boucle est interrompue lorsque le critère de stabilité ϵ est atteint, indiquant une convergence de la surface de coût (la modification du prédicteur entre deux itérations devient négligeable).
- **Génration du chemin optimal**
  - Extraction de l'itinéraire optimal par minimisation de la fonction de coût agrégée par algorithme du plus court chemin (se référer à 3.2.1 pour plus de détails)).
  - Analyse de sensibilité et calcul des indicateurs de performance (indice de confiance, robustesse aux incertitudes).

Le lecteur est invité à consulter l'Annexe 2 pour voir l'algorithme détaillé de la chaîne de traitement. Une représentation visuelle de la pipeline est en Figure 3.1.

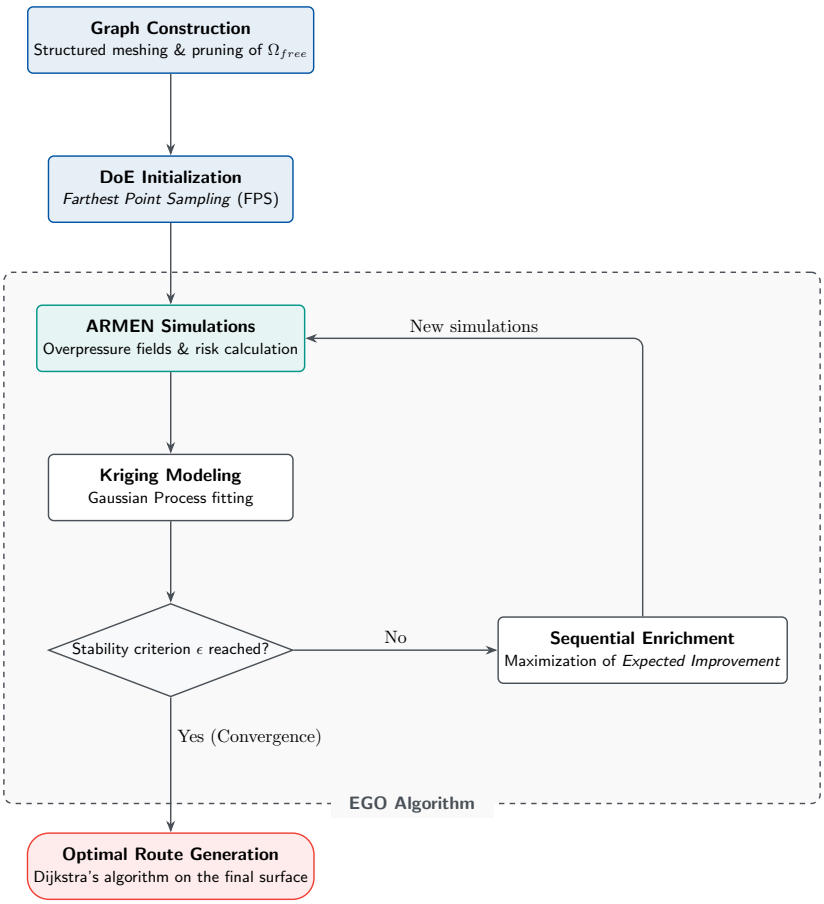

FIGURE 3.1 – Schéma de l'architecture de la chaîne de traitement

3.2 Choix des algorithmes

3.2.1 Plus court chemin

Le choix de l'algorithme de plus court chemin s'est porté entre les approches classiques de type **Dijkstra** et **A***.

L'algorithme A* présente en théorie un avantage en termes de performance grâce à l'utilisation d'une heuristique permettant de guider la recherche. Cependant, dans notre cas d'étude, la taille du graphe reste suffisamment réduite pour permettre une exécution rapide de l'algorithme de Dijkstra en séquentiel.

Ainsi, l'utilisation de Dijkstra a été privilégiée pour sa simplicité de mise en œuvre et son caractère déterministe, sans nécessité de définir une heuristique adaptée. Par ailleurs, le graphe utilisé repose sur un maillage quadrillé incluant les déplacements diagonaux, ce qui permet d'obtenir des trajectoires plus naturelles et de limiter notamment les sollicitations à haute fréquence du véhicule le long de son chemin.

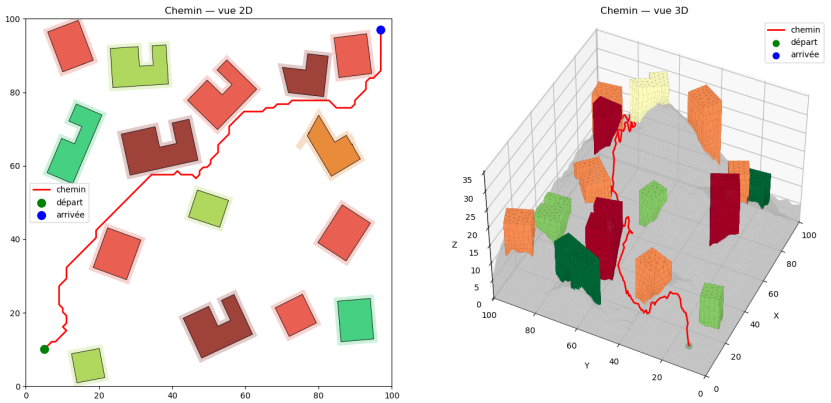

FIGURE 3.2 – Exemple de plus court chemin calculé sur le graphe 3D pondéré par les distances

3.2.2 k-dominating set

L'objectif est de sélectionner un sous-ensemble de nœuds du graphe permettant à la fois une **bonne couverture** et une **répartition spatiale homogène**. D'un point de vue combinatoire, un k-dominating set est défini comme un ensemble de nœuds tel que tout nœud du graphe soit à une distance au plus k d'au moins un nœud sélectionné. Cette contrainte traduit une exigence de **couverture**, tandis que notre objectif applicatif impose également une **dispersion** suffisante des points sélectionnés afin d'éviter des redondances spatiales.

Plusieurs approches ont été envisagées :

— Algorithme glouton (couverture)
— KNN (K-Nearest Neighbors) (granularité)
— K-means (granularité)
— FPS (Farthest Point Sampling) (dispersion)

Parmi les critères d'évaluation, on retient un temps de calcul raisonnable, une bonne couverture du graphe (au sens du k-dominating set) et une dispersion maximale des nœuds sélectionnés.

Les méthodes de clustering telles que K-means ou KNN privilégient une structuration globale des données en groupes. Dans le cas de KNN, le paramètre k contrôle directement la granularité : lorsque k augmente, le nombre de groupes diminue. Ce paramètre doit donc être ajusté en fonction du niveau de détail souhaité. Cependant, ces approches ne garantissent ni une couverture explicite du graphe au sens du k-dominating set, ni une maximisation des distances minimales entre points.

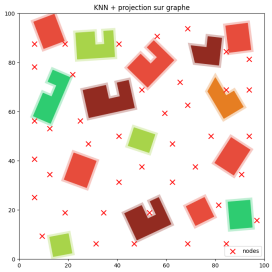

FIGURE 3.3 – $k = 50$

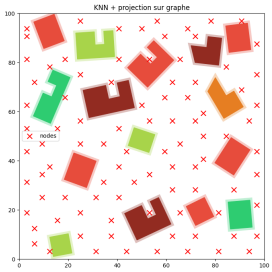

FIGURE 3.4 – $k = 20$

Par ailleurs, cette méthode n'est pas symétrique : elle dépend de l'ordre dans lequel les points sont considérés. Ainsi, selon que l'analyse est initiée à partir des points situés en bas à gauche ou en haut à droite, on obtient des graphes visuellement différents.

L'algorithme glouton, quant à lui, privilégie la **couverture**. À chaque itération, il sélectionne le nœud couvrant le plus de nœuds encore non couverts dans un rayon donné r. Cette approche satisfait naturellement la contrainte du k-dominating set, mais dépend fortement du choix de r et peut conduire à une distribution spatiale irrégulière, avec des nœuds très proches en fin de processus. De plus, le calcul des voisinages repose sur des plus courts chemins (Dijkstra), ce qui induit un coût de calcul élevé, typiquement en $O(n^2)$ dans notre cas. Enfin, la méthode reste sensible à l'ordre de sélection et peut produire des solutions sous-optimales.

À l'inverse, l'approche **Farthest Point Sampling (FPS)** privilégie la **dispersion**. Elle sélectionne itérativement les points maximisant leur distance minimale aux points déjà choisis. Cette méthode, de complexité $O(kn)$, travaille directement dans l'espace 3D et permet d'obtenir une répartition homogène et bien espacée des nœuds. Elle ne garantit pas strictement la propriété de couverture du k-dominating set, mais fournit un échantillonnage spatial particulièrement pertinent dans notre contexte.

Finalement, l'approche **Farthest Point Sampling (FPS)** a été retenue car, expérimentalement, elle maximise la distance entre les points sélectionnés. Cela correspond directement à l'objectif recherché : obtenir un sous-ensemble de nœuds à la fois informatif et spatialement bien réparti pour les simulations, tout en conservant un coût de calcul maîtrisé.

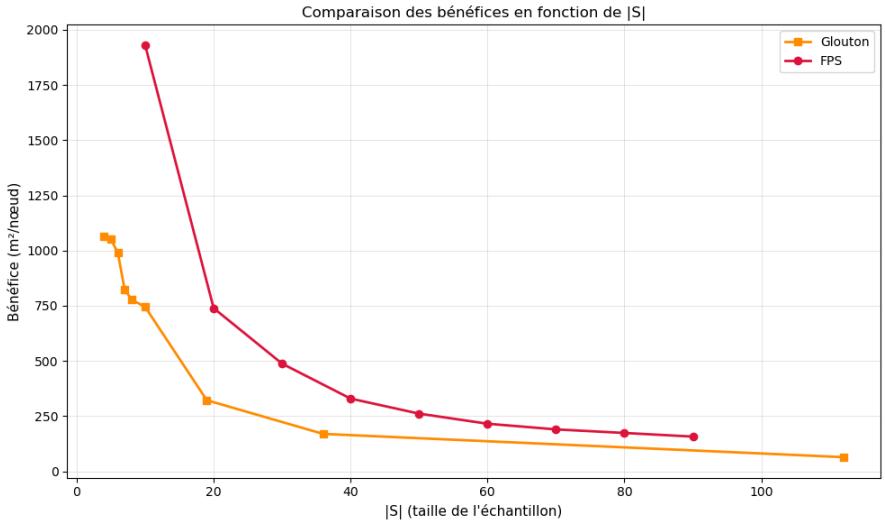

FIGURE 3.5 – Comparaison entre les méthodes gloutonne et FPS : le bénéfice est défini comme la moyenne, sur les nœuds du dominating set, de la distance au carré à leur plus proche voisin

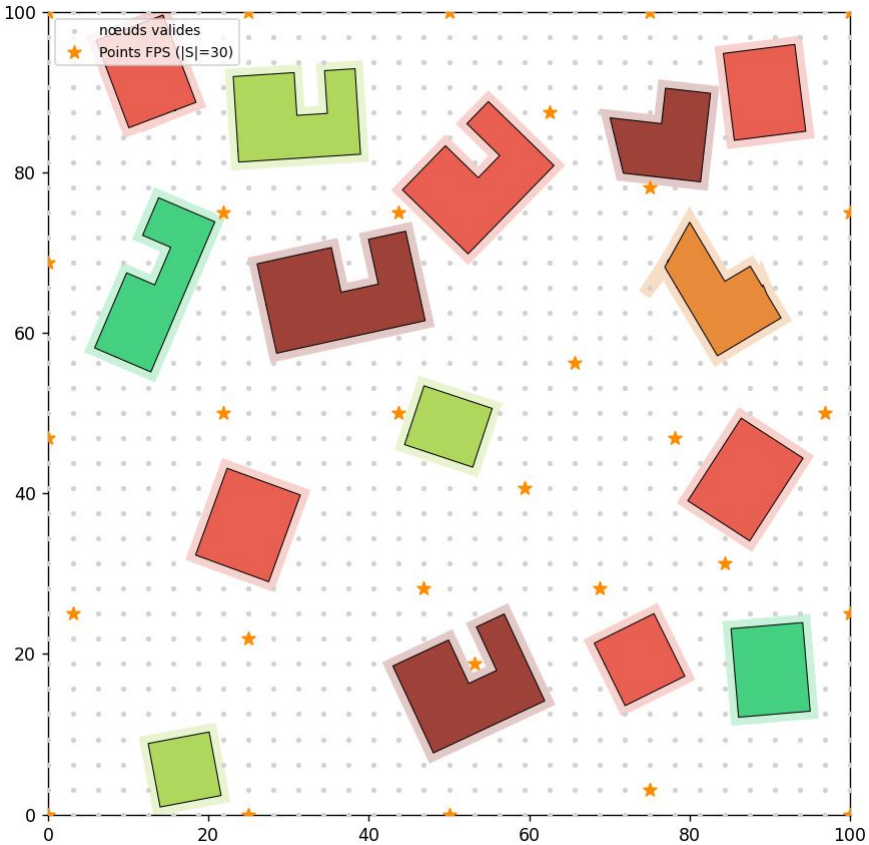

FIGURE 3.6 – Exemple de dominating set obtenu par la méthode FPS pour $k = 30$

3.2.3 Modélisation par Processus Gaussiens de la fonction coût

L'enjeu central de cette phase réside dans la reconstruction d'une approximation fidèle de la fonction de coût sur le domaine admissible Ω_{free}. Cette tâche est contrainte par le coût élevé des simulations physiques (ARMEN), qui impose une cardinalité d'échantillonnage réduite. Il existe donc un compromis entre fidélité de l'approximation et nombre de simulations réalisables.

Insuffisance des approches déterministes

Une approche déterministe classique (régression polynomiale, surfaces de réponse par moindres carrés) s'avère ici insuffisante. En effet, la minimisation de l'erreur résiduelle globale $\|f - \hat{f}\|$ ne garantit en rien la précision de la localisation

des extrema. Il existe une déconnexion mathématique entre la fidélité globale du métamodèle et la convergence de ses optima [3] :

$$\|f - \hat{f}\| \to 0 \;\not\Rightarrow\; \begin{cases} |\min(f) - \min(\hat{f})| \to 0 \\ \|\operatorname{argmin}(f) - \operatorname{argmin}(\hat{f})\| \to 0 \end{cases} \tag{3.1}$$

Pour pallier cette limite, nous adoptons le cadre de l'**Optimisation Bayésienne** [4]. Ce changement de paradigme consiste à traiter la fonction de coût non plus comme déterministe et figée, mais comme une réalisation d'un **Processus Gaussien** (PG).

Le métamodèle probabiliste : krigeage

Le lecteur est invité à consulter l'Annexe 1 pour une formalisation détaillée du cadre mathématique (définitions et démonstrations) et l'Annexe 2 pour le détail de l'algorithme.

Au lieu de chercher une fonction unique $\hat{f}$ approchant f, on définit une loi de probabilité sur l'espace des fonctions, conditionnée par l'ensemble des observations $(\mathbf{X}, \mathbf{Y}) = \{(\mathbf{x}_i, f(\mathbf{x}_i))\}_{i=1,\dots,n}$. La fonction inconnue f est modélisée comme une réalisation d'un processus gaussien $Y(\mathbf{x})$ de moyenne $m(\mathbf{x})$ et de noyau de covariance $k(\mathbf{x}, \mathbf{x}')$. Conditionnellement aux observations, la distribution a posteriori du coût en tout point $\mathbf{x}$ suit une loi normale (cf. Proposition 7.1.1 en Annexe 1) :

$$[Y(\mathbf{x}) \mid Y(\mathbf{X}) = \mathbf{Y}] \sim \mathcal{N}\big(m_n(\mathbf{x}),\ s_n^2(\mathbf{x})\big) \tag{3.2}$$

Ce formalisme fait émerger deux composantes complémentaires pour la prise de décision :

— La **moyenne de krigeage** $m_n(\mathbf{x})$, donnée par l'équation (7.5) : elle constitue l'estimateur ponctuel du coût, c'est-à-dire le métamodèle proprement dit. Le krigeage réalise une interpolation exacte des observations ($m_n(\mathbf{x}_i) = f(\mathbf{x}_i)$).

— La **variance de krigeage** $s_n^2(\mathbf{x})$, donnée par l'équation (7.6) : elle quantifie l'*incertitude épistémique*, c'est-à-dire le manque de connaissance du modèle dans les zones peu explorées de Ω_{free}. Cette variance s'annule aux points d'observation et croît avec la distance au plan d'expériences.

Les hyperparamètres du noyau de covariance (variance σ^2, portées ψ_j) sont estimés par maximum de vraisemblance à partir des observations disponibles (cf. équation (7.7) en Annexe 1).

Enrichissement séquentiel par le critère d'Expected Improvement

L'intérêt de l'Optimisation Bayésienne est double. D'une part, elle permet de quantifier mathématiquement l'incertitude sur le métamodèle, et donc la fiabilité de la surface de coût approximée. D'autre part, cette incertitude peut être exploitée pour guider l'échantillonnage en identifiant le point dont la simulation apporterait le maximum d'information.

Nous utilisons pour cela le critère d'**Expected Improvement** (EI), introduit par Mockus *et al.* (1978) et popularisé par Jones *et al.* [4]. Soit $f_{\min} = \min_{i=1,\dots,n} f(\mathbf{x}_i)$ le meilleur coût observé. L'EI mesure le gain espéré d'une évaluation en $\mathbf{x}$:

$$\mathrm{EI}(\mathbf{x}) = \mathbb{E}\big[(f_{\min} - Y(\mathbf{x}))^+ \;\big|\; Y(\mathbf{X}) = \mathbf{Y}\big] \tag{3.3}$$

Ce critère admet une expression analytique (cf. Proposition 7.2.1 et sa démonstration en Annexe 1) :

$$\mathrm{EI}(\mathbf{x}) = (f_{\min} - m_n(\mathbf{x}))\,\Phi(u) + s_n(\mathbf{x})\,\phi(u), \qquad u = \frac{f_{\min} - m_n(\mathbf{x})}{s_n(\mathbf{x})}, \tag{3.4}$$

où Φ et ϕ sont respectivement la fonction de répartition et la densité de la loi $\mathcal{N}(0,1)$.

Ce critère réalise automatiquement un compromis entre deux stratégies complémentaires :

1. **Exploitation** : le terme $(f_{\min} - m_n(\mathbf{x}))\,\Phi(u)$ est élevé dans les zones où la moyenne prédite est faible, c'est-à-dire les zones à coût potentiellement faible.
2. **Exploration** : le terme $s_n(\mathbf{x})\,\phi(u)$ est élevé dans les zones où l'incertitude est grande, c'est-à-dire les zones méconnues du domaine.

L'algorithme EGO (*Efficient Global Optimization*) procède alors de manière séquentielle : à chaque itération, le point maximisant l'EI est sélectionné, la simulation y est exécutée, le modèle de krigeage est mis à jour, et le processus est réitéré jusqu'à convergence ($\max_{\mathbf{x}} \mathrm{EI}(\mathbf{x}) < \varepsilon$) ou épuisement du budget.

Parallélisation par le critère q-EI

Dans notre contexte, où plusieurs simulations peuvent être lancées simultanément sur q processeurs, le critère d'Expected Improvement multipoints (q-EI) [2] permet de sélectionner un lot de q points d'évaluation en une seule itération. Ce critère généralise l'EI en mesurant le gain espéré conjoint d'une évaluation simultanée aux q points candidats (cf. Annexe 1, éq. (7.16)).

En conclusion, l'Optimisation Bayésienne permet de réaliser un processus de simulation optimisé : elle concentre l'effort de calcul là où l'apport d'information est maximal, garantit une convergence rapide vers une approximation fidèle de la surface de coût, et fournit une quantification de l'incertitude résiduelle sur le métamodèle.

3.3 Optimisation du temps de calcul

3.3.1 Parallélisation

La parallélisation du calcul s'est trouvée indispensable du fait du grand nombre de simulations à effectuer sur le graphe, chacune nécessitant un temps d'exécution significatif, rendant toute approche séquentielle incompatible avec les contraintes temporelles du projet. On peut voir sur la figure suivante que pour une taille de mesh 50cm, le temps de calcul est déjà de 44s en 2D. En 3D, ce même mesh prendra 3min17.

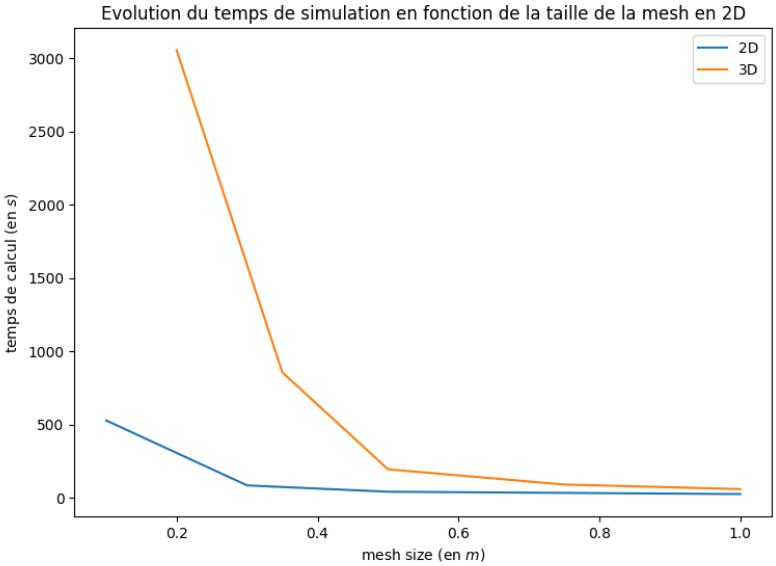

FIGURE 3.7 – Evolution du temps de simulation en fonction de la taille du mesh en 2D et en 3D.

Afin de rendre l'approche exploitable en pratique, plusieurs optimisations ont été mises en place :

- **Parallélisation des simulations d'explosion** : les simulations étant indépendantes, elles peuvent être exécutées en parallèle afin de réduire significativement le temps total de calcul.
- **Parallélisation de l'optimisation bayésienne** : certaines étapes, notamment l'évaluation de la fonction objectif ou la mise à jour du modèle, peuvent également être parallélisées pour accélérer la convergence.

3.3.2 Étude de sensibilité au maillage : choix du pas de simulation

Le pas de maillage par défaut de la simulation etait fixé à 0,1 m. Bien que cette résolution garantisse une haute fidélité physique, elle engendre des temps de calcul extrêmement lourds, particulièrement prohibitifs pour des études nécessitant le lancement de centaines de points de fonctionnement.

Afin d'optimiser le temps de restitution sans compromettre la validité des résultats, nous avons mené une étude de convergence spatiale. L'objectif est d'identifier le maillage le plus lâche possible capable de reproduire le même comportement macroscopique que le maillage de référence. Pour ce faire, nous avons utilisé la fonction de « risque de l'explosion » comme métrique de validation.

Le test a consisté à faire varier la taille du maillage de 0,1 m à 1,0 m et d'observer l'évolution du risque moyen évalué sur un échantillon de 30 points. Les résultats sont présentés sur la figure 3.8.

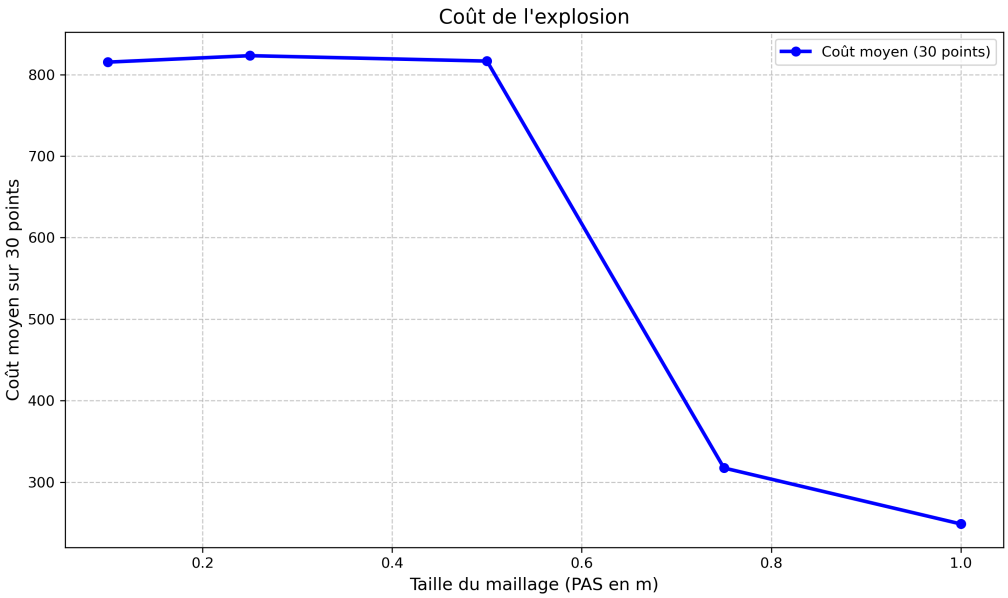

FIGURE 3.8 – Évolution du risque moyen de l'explosion en fonction du pas de la simulation

L'analyse de la courbe met en évidence deux régimes distincts :

— **Zone de stabilité (0,1 m à 0,5 m) :** Le risque moyen reste remarquablement constant, se stabilisant autour d'une valeur de 500. La physique de l'explosion est correctement capturée par la simulation, le maillage est suffisamment fin.

— **Zone de dégradation spatiale (au-delà de 0,5 m) :** On observe une chute drastique du risque moyen estimé. Le maillage devient trop grossier pour résoudre correctement les gradients et la dynamique du phénomène, entraînant une sous-estimation manifeste du résultat.

Cependant, cette approche, basée sur la comparaison des coûts globaux moyens, présente un biais méthodologique : elle permet la compensation des erreurs.

Pour pallier ce biais, pour chaque point d'explosion (X, Y), nous avons calculé l'erreur absolue locale entre le coût obtenu avec un maillage relâché et le coût de la référence stricte (pas de 0,1 cm). La moyenne de ces erreurs locales individuelles, ainsi que leur dispersion, sont présentées sur la figure 3.9.

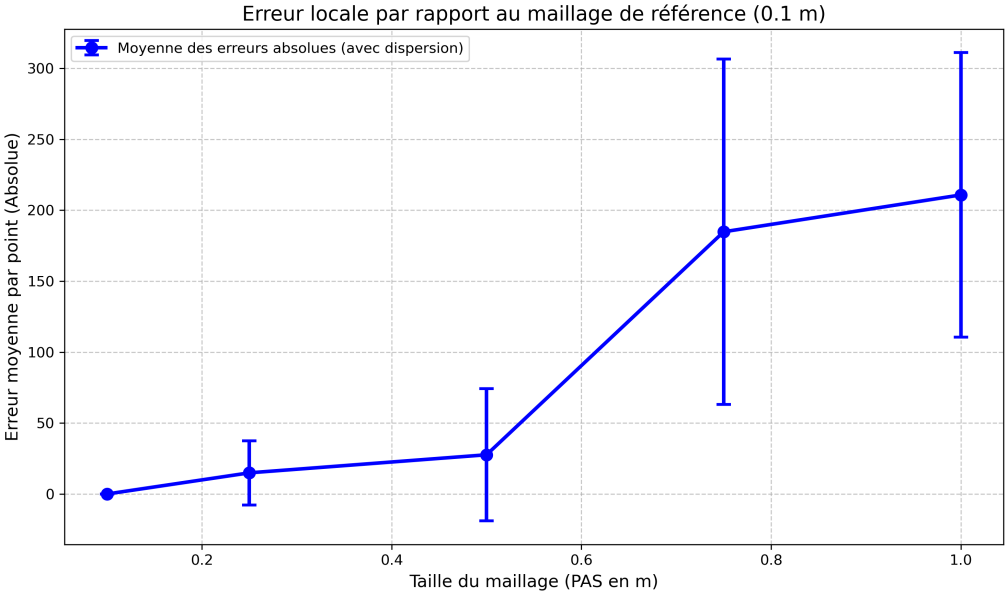

FIGURE 3.9 – Évolution de l'erreur absolue locale moyenne par point par rapport au maillage de référence (0,1 m).

L'analyse de ce nouveau graphique révèle la sensibilité de la simulation à la taille de la maille.

Par conséquent, cette étude justifie l'abandon du pas par défaut de 0,1 m au profit d'un pas de **0,25 m**. Ce choix

permet de réduire les temps de calcul, les passant de 5 minutes en moyenne par simulation à 130 secondes tout en garantissant que la fonction du risque reste strictement équivalente à celle obtenue avec une résolution maximale.

3.4 Scalabilité

Un code est scalable lorsqu'il peut traiter n'importe quel problème en temps constant, pourvu qu'il dispose des ressources nécessaires. Cela implique de diviser un gros problème en plusieurs petits problème occupant une mémoire limitée, traités sur des machines distinctes et avec des communications limitées. Ainsi le temps de calcul demeure presque constant.

Notre pipeline n'est pas scalable, car le code de krigeage n'est ni parallélisé, ni rendu scalable. Les étapes de simulation avec Armen et de post-traitement ont été rendues parallèles par soucis de temps de calcul réduit. Le choix de l'algorithme de plus court chemin s'est porté sur Dijkstra, qui est séquentiel, car son exécution est négligeable devant tout le reste.

Chapitre 4

Résultats et validation

4.1 Simulations

La validation de notre approche repose dans un premier temps sur l'observation de la convergence du métamodèle de krigeage au fil des itérations de l'algorithme EGO.

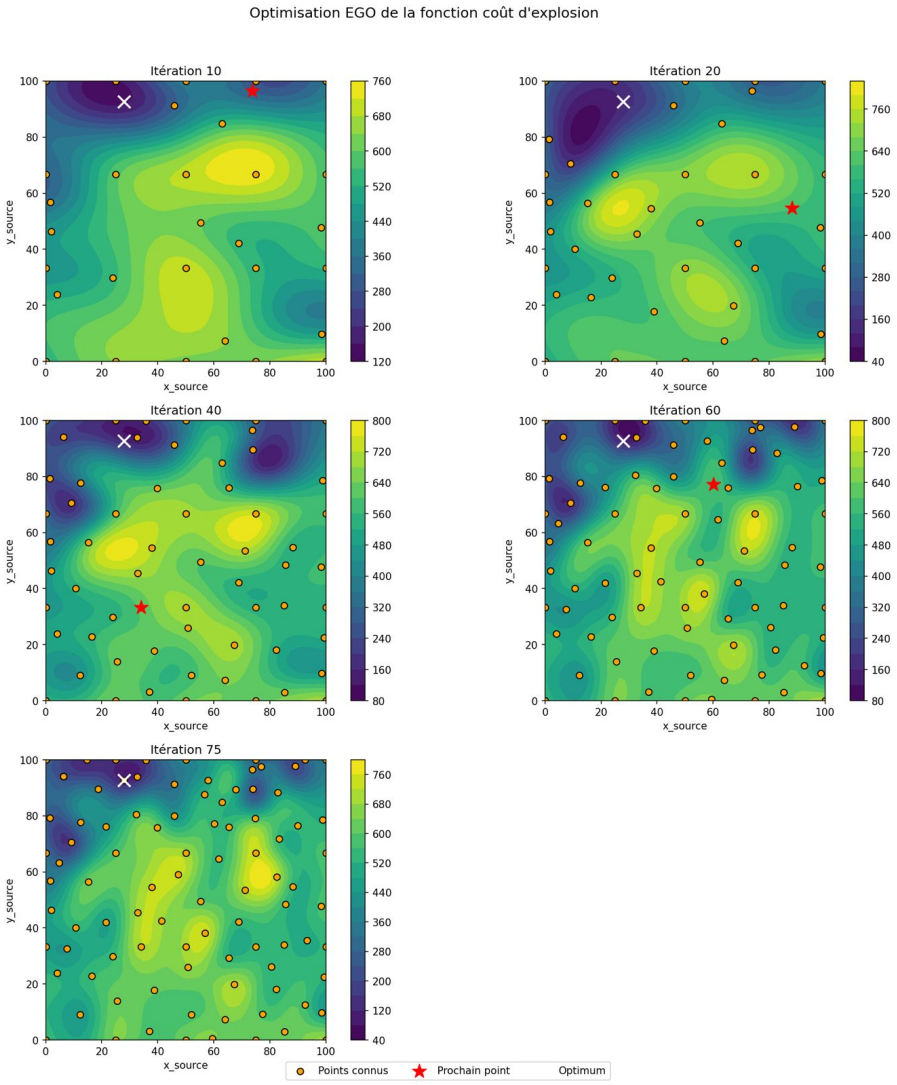

FIGURE 4.1 – Évolution de la carte de coût (risque) lors des itérations 71 à 75 de l'algorithme EGO. Les points orange représentent l'historique d'échantillonnage, l'étoile rouge indique le prochain point à évaluer, et la croix blanche repère l'optimum global estimé.

Sur ces cartographies, plusieurs éléments clés du processus d'optimisation bayésienne sont mis en évidence :

— **L'historique d'échantillonnage (points orange) :** L'augmentation progressive de la densité des points illustre

la transition entre l'échantillonnage initial (visible à l'itération 10, où la surface est encore très lissée) et un maillage intelligent et non uniforme à l'itération 75. L'algorithme densifie l'espace uniquement là où c'est nécessaire.

— **Le compromis exploration/exploitation (étoile rouge) :** Le prochain point à évaluer, dicté par la maximisation du critère *Expected Improvement* (EI), démontre la dynamique de l'algorithme. Lors des premières itérations (10 et 20), l'étoile cible de vastes zones éloignées des points existants pour réduire la variance globale du modèle (exploration pure). Aux itérations 40 et 60, le critère vient échantillonner et affiner des structures locales plus spécifiques, au bord des gradients de risque (compromis avec l'exploitation).

— **La stabilité de l'optimum (croix blanche) :** la zone de l'optimum global estimé (située dans le couloir de moindre risque en haut à gauche, vers $x \approx 28, y \approx 92$) est identifiée dès les premières itérations et reste parfaitement stable jusqu'à l'itération 75. L'algorithme EGO sécurise donc très tôt la zone d'intérêt minimal sans gaspiller de ressources de calcul superflues dans ce secteur, se concentrant sur la cartographie des obstacles environnants.

Les zones jaunes (coût souvent supérieur à 600 ou 700) correspondent logiquement aux densités de bâtiments élevées ou aux infrastructures de catégorie critique, que le modèle parvient à détourer avec de plus en plus de précision au fil des évaluations, offrant ainsi une carte de risque robuste pour le calcul d'itinéraire.

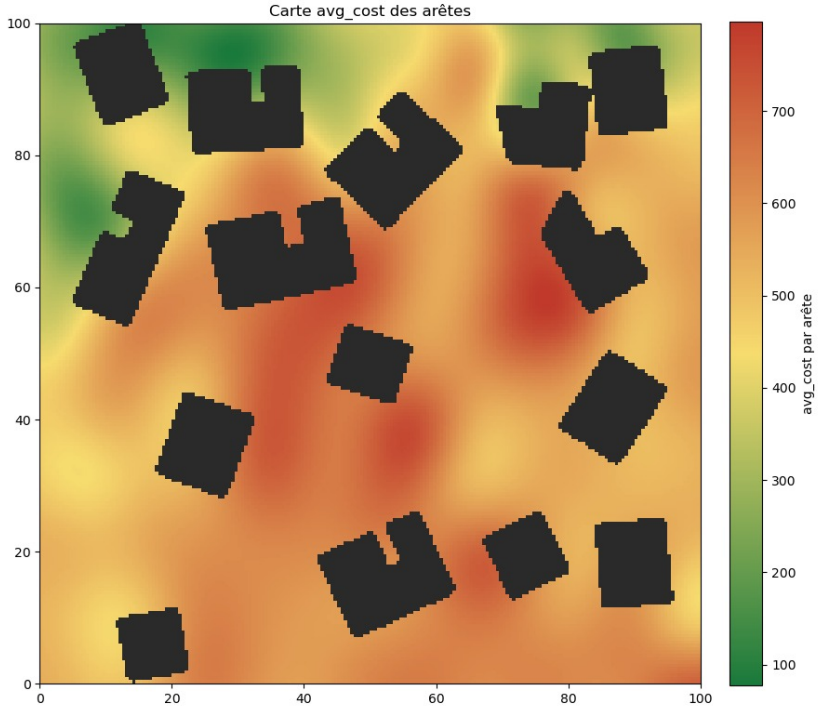

FIGURE 4.2 – Superposition de la cartographie des coûts (risque pyrotechnique) et de la topographie urbaine.

L'analyse de cette carte de coûts, superposée à la topologie de la ville, met en évidence les observations suivantes :

— Les zones de vulnérabilité maximale (coûts élevés) se concentrent logiquement à la périphérie immédiate des infrastructures critiques.

— Les minima de la fonction de coût coïncident avec les espaces dégagés, caractérisés par une absence d'obstacles bâtis.

— Une incohérence locale est toutefois observée dans le secteur nord-est (en haut à droite) : bien que ces infrastructures présentent un indice de criticité élevé, la cartographie y révèle un coût anormalement bas. Ce biais prédictif s'explique par une sous-estimation locale du métamodèle de krigeage, induite par une gestion sous-optimale des seuils de surpression dans cette zone. Un recalibrage rigoureux des hyperparamètres du krigeage, couplé à un affinement de la fonction de pénalité liée aux seuils de pression, permettra de corriger cette erreur d'approximation.

Ces résultats corroborent la cohérence spatiale de la surface de coût modélisée par optimisation bayésienne, confirmant ainsi la pertinence physique de la méthode employée.

4.2 Résultat final : chemin de coût minimal obtenu

4.2.1 Une fois le métamodèle entraîné, nous l'utilisons pour générer la surface de coût finale qui servira de base à l'algorithme de Dijkstra. Cette section détaille la trajectoire obtenue, en mettant en évidence l'importance d'une topologie précise et d'un calibrage fin de la fonction de risque.

4.2.1 Problème initial : Mauvaise détection topologique par EGO

Lors des premières phases de l'optimisation, nous avons été confrontés à un problème de modélisation. Comme l'illustre la Figure 4.3, le modèle de Krigeage a mal détecté un bâtiments de catégorie 5 situé au centre de la carte (coordonnées approximatives $x = 40, y = 40$).

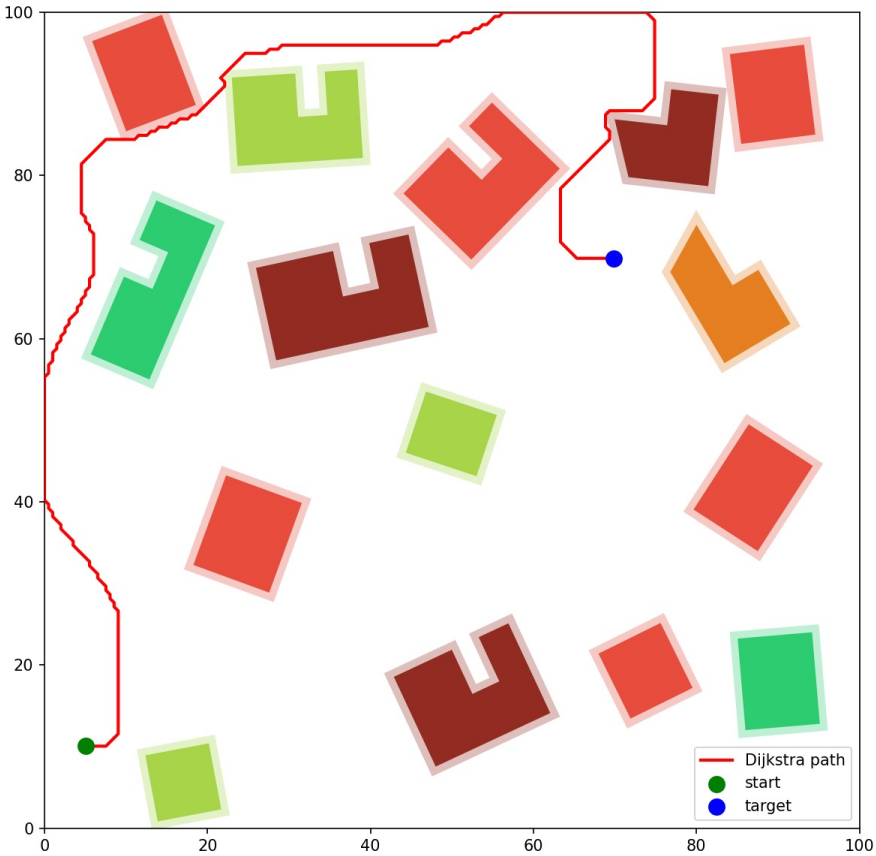

FIGURE 4.3 – Djikstra pour le premier modèle de Krigeage

Le Krigeage a produit un lissage excessif dans cette zone, prédisant un coût très faible là où des infrastructures stratégiques auraient dû générer un risque maximal. Ce problème a souligné la nécessité d'affiner l'échantillonnage de l'EGO pour forcer la détection précise des discontinuités topologiques.

4.2.2 Résolution et résultat final ($\alpha = 1,5$)

On rappelle la formulation de notre fonction de risque individuel pour un bâtiment i :

$$R_i = D_i \cdot e^{\alpha \cdot K_i} \tag{4.1}$$

où D_i est le taux de destruction physique et K_i sa catégorie d'importance stratégique ($K_i \in \{1, 2, 3, 4, 5\}$).

Dans notre scénario d'étude final, nous avons calibré le paramètre d'échelle à $\alpha = 1,5$. Ce choix applique une pénalité intermédiaire, suffisante pour forcer le détour face à des batiments de haute catégorie.

La Figure 4.4 présente la trajectoire finale générée avec ce paramétrage sur la carte corrigée.

L'analyse de ce résultat montre une trajectoire beaucoup plus cohérente qui s'écarte le plus possible des batiments de catégorie 5.

Pour chaque point du parcours, la position est également exportée dans un format structuré JSON, par exemple :

```
[
  { "x": 5.0251, "y": 10.0503 },
  { "x": 5.5276, "y": 10.0503 },
  { "x": 6.0302, "y": 10.0503 }
]
```

Cette liste permet de réutiliser directement l'itinéraire dans des applications de simulation, de guidage ou d'analyse complémentaire.

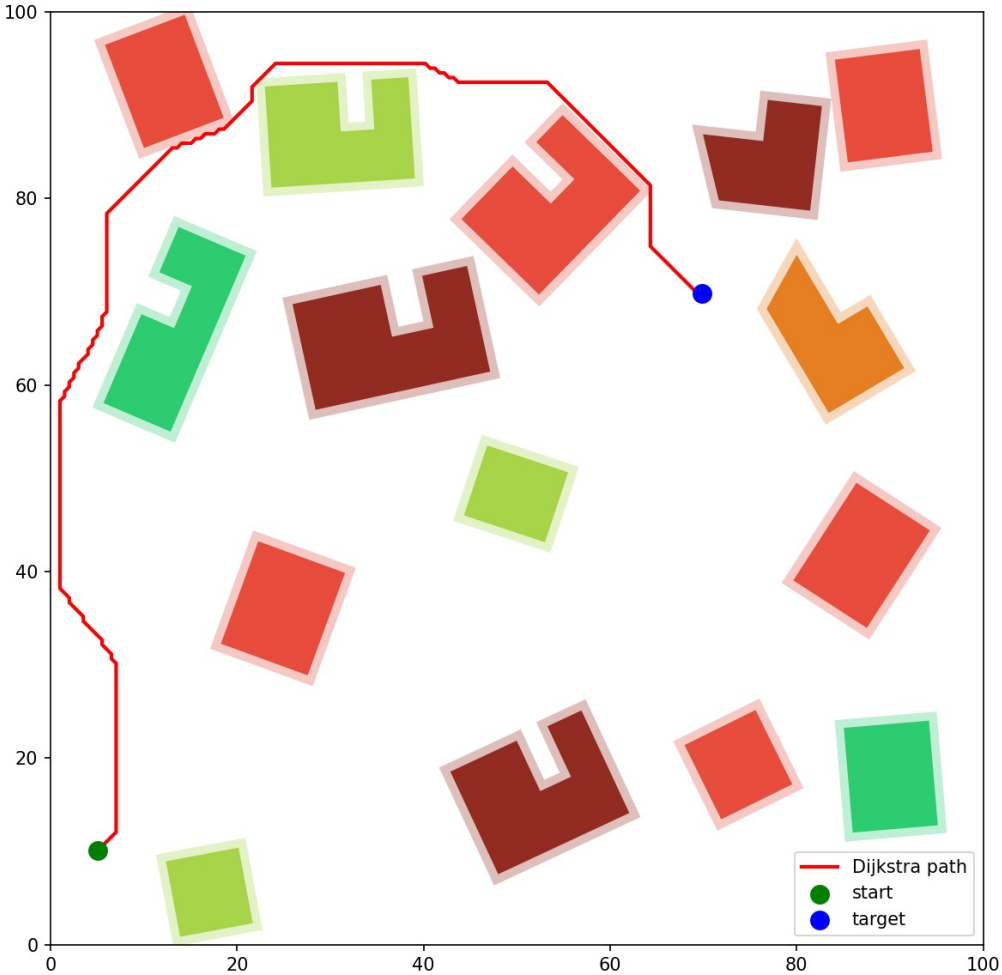

FIGURE 4.4 – Trajectoire optimale finale calculée par l'algorithme de Dijkstra (en rouge) sur la surface de coût corrigée avec $\alpha = 1,5$. Le chemin contourne efficacement les bâtiments critiques (jaunes/verts) identifiés au centre de la carte.

Chapitre 5

Perspectives

5.1 Améliorations possibles

Plusieurs axes d'amélioration peuvent être envisagés afin d'augmenter la précision et la robustesse du modèle proposé.

Tout d'abord, la fonction de coût pourrait être enrichie afin de mieux refléter les contraintes physiques du véhicule. Par exemple, l'introduction d'une pénalisation sur la courbure de la trajectoire permettrait de limiter les changements brusques de direction, en complément de la pénalisation déjà introduite sur les variations d'altitude.

Par ailleurs, la discrétisation du graphe constitue une approximation de l'espace continu. L'utilisation de maillages adaptatifs, plus fins dans les zones à fort risque et plus grossiers ailleurs, permettrait d'améliorer le compromis entre précision et coût de calcul.

Sur le plan de l'Optimisation Bayésienne (EGO), l'efficacité du processus pourrait être significativement accrue par une étude comparative de plusieurs critères d'acquisition (tels que l'Upper Confidence Bound ou la Predictive Entropy Search), afin d'affiner dynamiquement le compromis entre exploration et exploitation. En complément, l'intégration d'une modélisation multi-fidélité (co-krigeage) et un traitement pleinement bayésien des hyperparamètres renforceraient la robustesse statistique de nos prédictions, tout en accélérant la convergence de l'algorithme vers le minimum global face aux topologies urbaines complexes.

Enfin, des optimisations algorithmiques pourraient être envisagées, notamment via des structures de données plus efficaces ou des versions parallélisées des algorithmes de plus court chemin et de calcul du k-dominating set.

5.2 Extensions envisageables

Une première piste consiste à intégrer des contraintes dynamiques plus réalistes, issues du contrôle de systèmes (vitesse, accélération, limitations mécaniques), rapprochant ainsi le modèle d'une application embarquée réelle.

Chapitre 6

Conclusion

Ce projet, mené en collaboration avec le CEA DAM, visait à répondre à un défi de sécurité publique critique : l'acheminement sécurisé d'engins explosifs instables en milieu urbain dense.

Une réponse concrète au défi initial

Nous avons apporté une réponse à cette problématique par la conception d'une chaîne de traitement numérique complète, de la lecture de la carte à l'extraction du trajet.

- **Priorisation de la vie urbaine** : En intégrant les catégories des bâtiments dans notre fonction de coût, nous garantissons un évitement des zones les plus vulnérables.
- **Réalisme et réactivité** : L'optimisation du maillage, associée à la parallélisation sur supercalculateur, permet de fournir une solution en un temps compatible avec l'urgence opérationnelle du déminage.

Chapitre 7

Annexe 1 – Fondements mathématiques de l'optimisation bayésienne

Cette annexe formalise le cadre mathématique des outils utilisés dans ce projet : la modélisation par processus gaussiens (krigeage), le critère d'amélioration espérée (EI) et l'algorithme EGO (*Efficient Global Optimization*).

7.1 Processus Gaussiens et Krigeage

7.1.1 Modèle probabiliste

Soit $f : D \subset \mathbb{R}^d \to \mathbb{R}$ la fonction de coût inconnue, supposée déterministe mais coûteuse à évaluer. Le krigeage modélise f comme une réalisation d'un processus gaussien $Y(\mathbf{x})$, défini par :

— une fonction moyenne $m(\mathbf{x}) = \mathbb{E}[Y(\mathbf{x})]$,
— un noyau de covariance $k(\mathbf{x}, \mathbf{x}') = \mathrm{Cov}(Y(\mathbf{x}), Y(\mathbf{x}'))$.

Définition 7.1.1 (Processus Gaussien)**.** Un processus stochastique $\{Y(\mathbf{x})\}_{\mathbf{x}\in D}$ est un processus gaussien si, pour tout sous-ensemble fini $\{\mathbf{x}_1, \dots, \mathbf{x}_n\} \subset D$, le vecteur aléatoire $(Y(\mathbf{x}_1), \dots, Y(\mathbf{x}_n))^\top$ suit une loi gaussienne multivariée.

Dans le cadre du krigeage ordinaire, la moyenne est supposée constante et inconnue : $m(\mathbf{x}) = \mu \in \mathbb{R}$. Le noyau de covariance encode les hypothèses de régularité sur f. On utilise typiquement un noyau de la famille de Matérn :

$$k(\mathbf{x}, \mathbf{x}') = \sigma^2 \frac{2^{1-\nu}}{\Gamma(\nu)} \left(\frac{\sqrt{2\nu}\, \|\mathbf{x} - \mathbf{x}'\|}{\rho} \right)^\nu K_\nu \left(\frac{\sqrt{2\nu}\, \|\mathbf{x} - \mathbf{x}'\|}{\rho} \right), \tag{7.1}$$

où σ^2 est la variance du processus, ρ la portée (distance de corrélation), ν le paramètre de régularité, Γ la fonction gamma et K_ν la fonction de Bessel modifiée de seconde espèce. Un cas particulier très répandu est le noyau gaussien (limite $\nu \to +\infty$) :

$$k(\mathbf{x}, \mathbf{x}') = \sigma^2 \exp\left(-\sum_{j=1}^{d} \frac{(x_j - x'_j)^2}{\psi_j^2} \right), \tag{7.2}$$

où les ψ_j sont les longueurs de corrélation par dimension (noyau anisotrope).

7.1.2 Prédiction par Krigeage Ordinaire

On suppose disposer d'un plan d'expériences $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\} \subset D$ et des observations associées $\mathbf{Y} = (f(\mathbf{x}_1), \dots, f(\mathbf{x}_n))^\top$.

Définition 7.1.2 (Notations matricielles)**.** On définit :

— $\mathbf{K} \in \mathbb{R}^{n\times n}$ la matrice de covariance : $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$,
— $\mathbf{k}(\mathbf{x}) \in \mathbb{R}^n$ le vecteur de covariances croisées : $k_i(\mathbf{x}) = k(\mathbf{x}_i, \mathbf{x})$,
— $\mathbf{1}_n = (1, \dots, 1)^\top \in \mathbb{R}^n$.

Le krigeage ordinaire cherche le prédicteur linéaire non biaisé de variance d'erreur minimale, c'est-à-dire $\hat{Y}(\mathbf{x}) = \boldsymbol{\lambda}(\mathbf{x})^\top \mathbf{Y}$ minimisant $\mathbb{E}[(\hat{Y}(\mathbf{x}) - Y(\mathbf{x}))^2]$ sous la contrainte de non-biais $\mathbf{1}_n^\top \boldsymbol{\lambda}(\mathbf{x}) = 1$. La résolution par multiplicateurs de Lagrange conduit au système :

$$\begin{pmatrix} \mathbf{K} & \mathbf{1}_n \\ \mathbf{1}_n^\top & 0 \end{pmatrix} \begin{pmatrix} \boldsymbol{\lambda}(\mathbf{x}) \\ \mu_L(\mathbf{x}) \end{pmatrix} = \begin{pmatrix} \mathbf{k}(\mathbf{x}) \\ 1 \end{pmatrix}, \tag{7.3}$$

où $\mu_L(\mathbf{x})$ est le multiplicateur de Lagrange.

Proposition 7.1.1 (Équations du Krigeage Ordinaire)**.** Sous l'hypothèse gaussienne, la loi conditionnelle de $Y(\mathbf{x})$ sachant $Y(\mathbf{X}) = \mathbf{Y}$ est gaussienne :

$$[Y(\mathbf{x}) \mid Y(\mathbf{X}) = \mathbf{Y}] \sim \mathcal{N}\big(m_n(\mathbf{x}),\ s_n^2(\mathbf{x})\big), \tag{7.4}$$

avec la moyenne de krigeage (prédicteur) :

$$m_n(\mathbf{x}) = \hat{\mu} + \mathbf{k}(\mathbf{x})^\top \mathbf{K}^{-1}(\mathbf{Y} - \hat{\mu}\,\mathbf{1}_n), \tag{7.5}$$

où $\hat{\mu} = \dfrac{\mathbf{1}_n^\top \mathbf{K}^{-1}\mathbf{Y}}{\mathbf{1}_n^\top \mathbf{K}^{-1}\mathbf{1}_n}$ est l'estimateur des moindres carrés généralisés de μ, et la variance de krigeage (incertitude) :

$$s_n^2(\mathbf{x}) = \sigma^2 - \mathbf{k}(\mathbf{x})^\top \mathbf{K}^{-1}\mathbf{k}(\mathbf{x}) + \frac{\left(1 - \mathbf{1}_n^\top \mathbf{K}^{-1}\mathbf{k}(\mathbf{x})\right)^2}{\mathbf{1}_n^\top \mathbf{K}^{-1}\mathbf{1}_n}. \tag{7.6}$$

Remarque 7.1.1 (Propriété d'interpolation)**.** Le krigeage est un interpolateur exact : $m_n(\mathbf{x}_i) = f(\mathbf{x}_i)$ et $s_n^2(\mathbf{x}_i) = 0$ pour tout $\mathbf{x}_i \in \mathbf{X}$ (se référer à [5] pour une démonstration de ces résultats). La variance de krigeage ne dépend pas des valeurs observées $\mathbf{Y}$ mais uniquement de la géométrie du plan d'expériences et du noyau de covariance.

7.1.3 Estimation des hyperparamètres

Les paramètres du noyau $\boldsymbol{\theta} = (\sigma^2, \rho, \nu)$ (ou $(\sigma^2, \psi_1, \ldots, \psi_d)$ pour le noyau gaussien anisotrope) sont estimés par maximum de vraisemblance. La log-vraisemblance des observations s'écrit :

$$\log L(\boldsymbol{\theta}) = -\frac{n}{2}\log(2\pi) - \frac{1}{2}\log|\mathbf{K}_{\boldsymbol{\theta}}| - \frac{1}{2}(\mathbf{Y} - \hat{\mu}\mathbf{1}_n)^\top \mathbf{K}_{\boldsymbol{\theta}}^{-1}(\mathbf{Y} - \hat{\mu}\mathbf{1}_n), \tag{7.7}$$

Les hyperparamètres sont obtenus par :

$$\hat{\boldsymbol{\theta}} = \arg\max_{\boldsymbol{\theta}} \log L(\boldsymbol{\theta}) \tag{7.8}$$

7.2 Critère d'amélioration espérée (Expected Improvement)

7.2.1 Motivation

L'approche naïve consistant à minimiser le prédicteur $m_n(\mathbf{x})$ conduit à une recherche purement locale. En effet, une bonne approximation globale de f ne garantit pas la convergence des extrema :

$$\|m_n - f\| \to 0 \;\not\Rightarrow\; |\min(m_n) - \min(f)| \to 0. \tag{7.9}$$

Le cadre probabiliste offre un outil plus puissant : la variance de krigeage $s_n^2(\mathbf{x})$ quantifie l'incertitude en chaque point, permettant de construire des critères d'exploration.

7.2.2 Définition et formule analytique

Soit $f_{\min} = \min_{i=1,\ldots,n} f(\mathbf{x}_i)$ le meilleur résultat observé. L'amélioration en un point $\mathbf{x}$ est la variable aléatoire :

$$I(\mathbf{x}) = \max(f_{\min} - Y(\mathbf{x}),\ 0) = (f_{\min} - Y(\mathbf{x}))^+ . \tag{7.10}$$

Définition 7.2.1 (Expected Improvement)**.** Le critère d'amélioration espérée est défini par :

$$\mathrm{EI}(\mathbf{x}) = \mathbb{E}\big[(f_{\min} - Y(\mathbf{x}))^+ \;\big|\; Y(\mathbf{X}) = \mathbf{Y}\big]. \tag{7.11}$$

Proposition 7.2.1 (Formule analytique de l'EI)**.** Puisque $[Y(\mathbf{x}) \mid Y(\mathbf{X}) = \mathbf{Y}] \sim \mathcal{N}(m_n(\mathbf{x}), s_n^2(\mathbf{x}))$, l'EI admet l'expression fermée :

$$\mathrm{EI}(\mathbf{x}) = \begin{cases} (f_{\min} - m_n(\mathbf{x}))\,\Phi(u) + s_n(\mathbf{x})\,\phi(u) & \text{si } s_n(\mathbf{x}) > 0, \\ 0 & \text{si } s_n(\mathbf{x}) = 0, \end{cases} \tag{7.12}$$

où

$$u = \frac{f_{\min} - m_n(\mathbf{x})}{s_n(\mathbf{x})}, \tag{7.13}$$

et Φ, ϕ désignent respectivement la fonction de répartition et la densité de la loi $\mathcal{N}(0,1)$.

Démonstration. On écrit $Y(\mathbf{x}) \mid \mathbf{Y} = m_n(\mathbf{x}) + s_n(\mathbf{x})\,Z$ avec $Z \sim \mathcal{N}(0,1)$. Alors :

$$\begin{aligned} \mathrm{EI}(\mathbf{x}) &= \mathbb{E}\big[(f_{\min} - m_n(\mathbf{x}) - s_n(\mathbf{x})\,Z)^+\big] \\ &= \int_{-\infty}^{u} (f_{\min} - m_n(\mathbf{x}) - s_n(\mathbf{x})\,z)\,\phi(z)\,dz \\ &= (f_{\min} - m_n(\mathbf{x}))\,\Phi(u) + s_n(\mathbf{x}) \int_{-\infty}^{u} (-z)\,\phi(z)\,dz. \end{aligned} \tag{7.14}$$

En utilisant $\int_{-\infty}^{u}(-z)\,\phi(z)\,dz = \phi(u)$ (propriété classique de la loi normale), on obtient (7.12). □

Remarque 7.2.1 (Compromis exploration–exploitation)**.** Le critère EI combine naturellement :

- un terme d'**exploitation** $(f_{\min} - m_n(\mathbf{x}))\,\Phi(u)$, élevé quand la moyenne prédite est faible (zone prometteuse),
- un terme d'**exploration** $s_n(\mathbf{x})\,\phi(u)$, élevé quand l'incertitude est grande (zone méconnue).

Ce compromis est automatique et ne requiert aucun paramètre de réglage, contrairement aux critères à seuil.

7.3 Algorithme EGO (*Efficient Global Optimization*)

L'algorithme EGO, introduit par Jones, Schonlau et Welch (1998) [4], est une procédure séquentielle d'optimisation globale reposant sur le krigeage et le critère EI.

Définition 7.3.1 (Algorithme EGO)**.** Étant donné un plan d'expériences initial $\mathbf{X}_0 = \{\mathbf{x}_1, \ldots, \mathbf{x}_{n_0}\}$ et les observations $\mathbf{Y}_0 = (f(\mathbf{x}_1), \ldots, f(\mathbf{x}_{n_0}))^\top$, l'algorithme procède itérativement :

1. **Modélisation :** Ajuster un modèle de krigeage (m_n, s_n^2) à partir de $(\mathbf{X}_n, \mathbf{Y}_n)$, en estimant les hyperparamètres $\hat{\boldsymbol{\theta}}$ par maximum de vraisemblance.
2. **Critère d'échantillonnage :** Calculer le prochain point d'évaluation :
$$\mathbf{x}_{n+1} = \arg\max_{\mathbf{x} \in D} \mathrm{EI}(\mathbf{x}). \tag{7.15}$$
3. **Évaluation :** Calculer $f(\mathbf{x}_{n+1})$ par simulation et enrichir le plan :
$$\mathbf{X}_{n+1} = \mathbf{X}_n \cup \{\mathbf{x}_{n+1}\}, \quad \mathbf{Y}_{n+1} = \mathbf{Y}_n \cup \{f(\mathbf{x}_{n+1})\}.$$
4. **Arrêt :** Répéter jusqu'à épuisement du budget de simulations ou convergence ($\max_{\mathbf{x}} \mathrm{EI}(\mathbf{x}) < \varepsilon$).

Remarque 7.3.1 (Propriété de convergence)**.** On peut montrer que, sous des hypothèses de régularité du noyau de covariance, l'algorithme EGO est dense dans D (tout point de D sera approché arbitrairement près par la suite $\{\mathbf{x}_n\}$), et que $f_{\min}^{(n)} \to f^*$ lorsque $n \to \infty$, où f^* désigne le minimum global de f sur D. (se référer à [5] pour une démonstration)

7.4 Extension au critère multipoints (q-EI)

Lorsque plusieurs simulations peuvent être exécutées simultanément sur q processeurs, on cherche un lot de q points $\{\mathbf{x}_{n+1}, \ldots, \mathbf{x}_{n+q}\}$ maximisant l'amélioration espérée conjointe.

Définition 7.4.1 (q-EI)**.** L'amélioration espérée à q points est :

$$\mathrm{EI}_q(\mathbf{x}_{n+1}, \ldots, \mathbf{x}_{n+q}) = \mathbb{E}\left[\left(f_{\min} - \min_{j=1,\ldots,q} Y(\mathbf{x}_{n+j})\right)^+ \,\middle|\, Y(\mathbf{X}) = \mathbf{Y}\right]. \tag{7.16}$$

Contrairement au cas $q = 1$, le q-EI n'admet pas de formule analytique simple pour $q \geq 2$. Son calcul repose sur une approximation par simulation de Monte-Carlo.

Proposition 7.4.1 (Calcul du q-EI par Monte-Carlo)**.** Soit $\mathbf{K}_{\mathrm{cond}} = \mathrm{Var}[(Y(\mathbf{x}_{n+1}), \ldots, Y(\mathbf{x}_{n+q}))^\top \mid \mathbf{Y}]$ la matrice de covariance conditionnelle, et $\mathbf{L}$ sa factorisation de Cholesky ($\mathbf{K}_{\mathrm{cond}} = \mathbf{L}\mathbf{L}^\top$). Alors pour N_{sim} simulations indépendantes $\mathbf{Z}^{(i)} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_q)$:

$$\widehat{\mathrm{EI}}_q = \frac{1}{N_{\mathrm{sim}}} \sum_{i=1}^{N_{\mathrm{sim}}} \left(f_{\min} - \min_{j=1,\ldots,q} \left[m_n(\mathbf{x}_{n+j}) + (\mathbf{L}\mathbf{Z}^{(i)})_j\right]\right)^+, \tag{7.17}$$

et par la loi des grands nombres $\widehat{\mathrm{EI}}_q \xrightarrow{\text{p.s.}} \mathrm{EI}_q$ lorsque $N_{\mathrm{sim}} \to +\infty$.

L'optimisation du q-EI est un problème de dimension dq qui devient rapidement coûteux. L'heuristique du **Constant Liar** (CL) offre une alternative pratique :

Définition 7.4.2 (Heuristique Constant Liar)**.** Soit $L \in \mathbb{R}$ une valeur fictive. On obtient q points de manière séquentielle :

1. Pour $j = 1, \ldots, q$: choisir $\mathbf{x}_{n+j} = \arg\max_{\mathbf{x}} \mathrm{EI}(\mathbf{x})$ avec le plan courant, puis ajouter le couple $(\mathbf{x}_{n+j}, L)$ au plan d'expériences (observation fictive).
2. Évaluer f en parallèle aux q points choisis, remplacer les mensonges par les vraies valeurs et ré-estimer le modèle.

Le choix $L = f_{\min}$ favorise l'exploration (répulsion modérée entre les points), tandis que $L = \max(\mathbf{Y})$ donne une répulsion forte.

7.5 Application au projet : synthèse de la chaîne de traitement

Dans le cadre de notre problème d'optimisation d'itinéraire, la chaîne complète s'articule comme suit :

1. **Plan d'expériences initial** : sélection de n_0 nœuds du graphe par *Farthest Point Sampling* pour maximiser la couverture spatiale de Ω_{free}.
2. **Simulations initiales** : évaluation de la fonction de coût (risque) en chaque point du plan initial par simulation physique.
3. **Construction du métamodèle** : ajustement d'un processus gaussien $(m_{n_0}, s_{n_0}^2)$ avec estimation des hyperparamètres par maximum de vraisemblance.
4. **Enrichissement séquentiel (EGO)** : à chaque itération, le critère EI (ou q-EI/CL pour l'enrichissement parallèle) identifie le(s) point(s) dont la simulation apporte le maximum d'information. La boucle est répétée jusqu'à ce que $\max_{\mathbf{x}} \mathrm{EI}(\mathbf{x}) < \varepsilon$ (convergence) ou que le budget soit épuisé.
5. **Extraction du chemin optimal** : la surface de coût approximée $m_n(\mathbf{x})$ est utilisée pour pondérer les arêtes du graphe, et l'algorithme de Dijkstra fournit l'itinéraire de moindre risque.

7.6 Validation sur fonctions tests analytiques

Afin de valider l'implémentation de la chaîne d'optimisation bayésienne avant son application au problème réel, nous présentons des résultats obtenus sur des fonctions tests dont l'expression analytique est connue. Cette démarche permet de mesurer objectivement la qualité du métamodèle en comparant la prédiction par krigeage à la vérité terrain, et d'observer le comportement du critère EI au fil des itérations.

L'implémentation repose sur la bibliothèque `SMT` (*Surrogate Modeling Toolbox*) [1], qui fournit une interface complète pour le krigeage et l'algorithme EGO.

7.6.1 Cas test 2D : fonction à oscillations couplées

On considère une fonction présentant des caractéristiques particulièrement difficiles pour un métamodèle : une tendance quadratique globale, des oscillations haute fréquence et un couplage non-linéaire :

$$f(\mathbf{x}) = \underbrace{0.1\left[(x_1-12)^2+(x_2-12)^2\right]}_{\text{tendance globale}} + \underbrace{10\left[\sin(1.5\,x_1)+\cos(1.5\,x_2)\right]}_{\text{oscillations}} + \underbrace{7\sin\!\left(\frac{x_1\,x_2}{10}\right)}_{\text{couplage}}, \tag{7.18}$$

définie sur le domaine $D = [0, 25]^2$. La Figure 7.1 présente la vérité terrain. La multiplicité des minima locaux et la brisure de symétrie induite par le terme de couplage rendent la reconstruction de cette surface particulièrement exigeante.

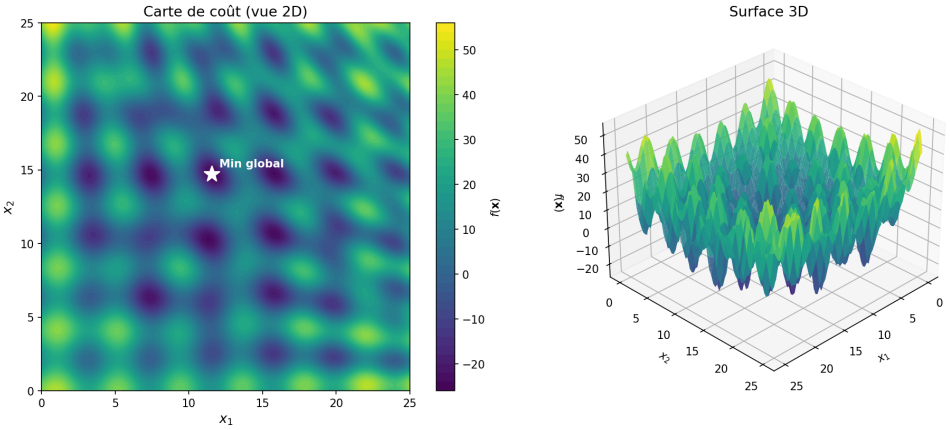

FIGURE 7.1 – Vérité terrain de la fonction test 2D (éq. (7.18)) : vue en contours (gauche) et surface 3D (droite). L'étoile blanche indique le minimum global.

7.6.2 Protocole expérimental

L'algorithme EGO est initialisé avec un plan d'expériences de $n_0 = 5$ points (4 sommets du domaine et le centre). Le critère EI est utilisé pour l'enrichissement séquentiel, avec un noyau de krigeage à estimation automatique des hyperparamètres par maximum de vraisemblance. L'algorithme est exécuté sur $N = 300$ itérations.

À chaque palier d'itérations, on évalue la qualité du métamodèle par la **RMSE** (*Root Mean Square Error*) calculée sur une grille dense de 100×100 points :

$$\mathrm{RMSE}(n) = \sqrt{\frac{1}{|G|}\sum_{\mathbf{x}\in G}\left(f(\mathbf{x}) - m_n(\mathbf{x})\right)^2}, \tag{7.19}$$

où G est la grille d'évaluation et m_n la moyenne de krigeage après n observations.

7.6.3 Résultats

La Figure 7.2 présente l'évolution conjointe de la prédiction (colonne de gauche) et de l'incertitude de krigeage $s_n(\mathbf{x}) = \sqrt{s_n^2(\mathbf{x})}$ (colonne de droite) au fil des itérations. On observe :

- **Itérations 10–40** : le métamodèle capture la tendance globale mais les oscillations restent mal résolues (RMSE $\approx$ 13–17). L'incertitude est élevée sur la quasi-totalité du domaine.
- **Itérations 80–150** : le critère EI dirige les évaluations vers les zones de forte incertitude. Les structures oscillantes commencent à apparaître (RMSE $\approx$ 9–13).
- **Itérations 200–250** : la convergence s'accélère. L'incertitude devient faible sur l'ensemble du domaine (zones noires sur la carte σ). La RMSE finale atteint 5.16, soit une réduction de 69% par rapport à l'itération 10.

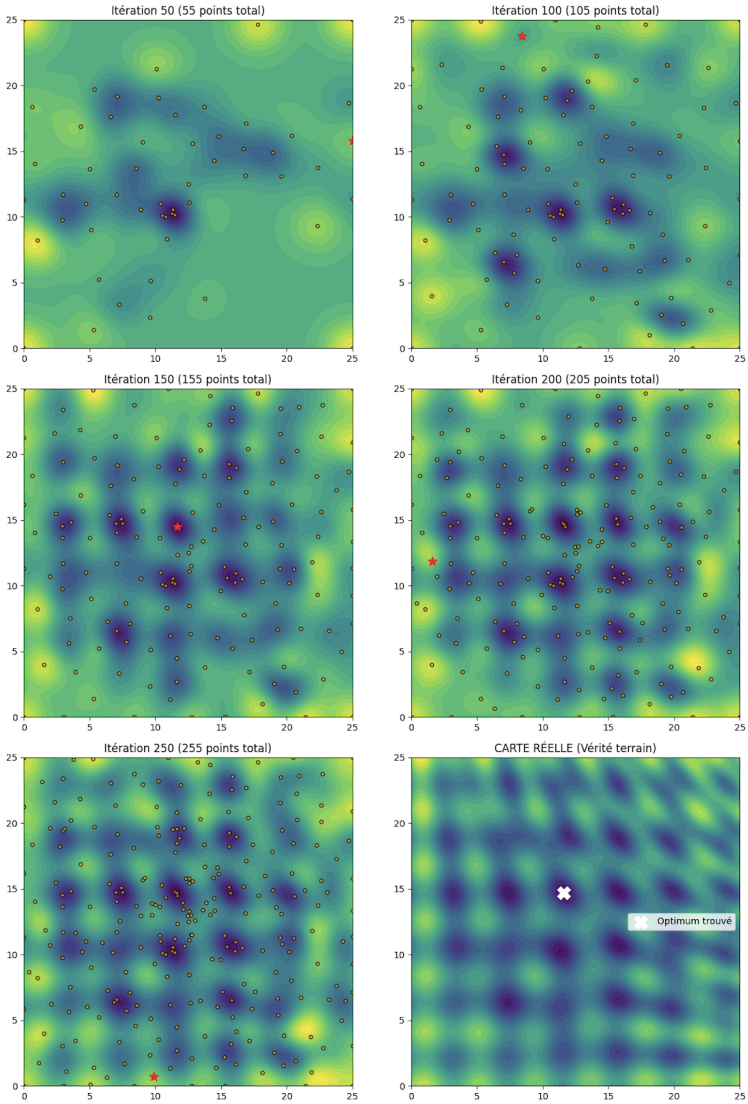

FIGURE 7.2 – Évolution du métamodèle EGO sur 250 itérations pour la fonction test 2D. Colonne de gauche : moyenne de krigeage $m_n(\mathbf{x})$ avec la RMSE associée. Colonne de droite : écart-type de krigeage $s_n(\mathbf{x})$ (zones sombres = incertitude faible). Les points blancs représentent les observations, l'étoile rouge le dernier point ajouté. La dernière ligne montre la vérité terrain.

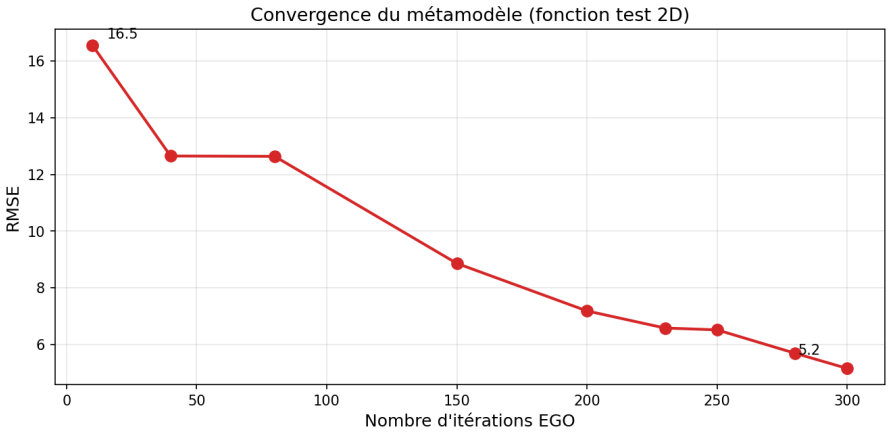

FIGURE 7.3 – Convergence de la RMSE du métamodèle en fonction du nombre d'itérations EGO. La décroissance de 16.5 à 5.2 en 300 itérations illustre l'efficacité de l'enrichissement séquentiel guidé par le critère EI.

Chapitre 8

Annexe 2 – Pseudo-code de l'algorithme d'enrichissement séquentiel

Cette annexe détaille l'algorithme complet utilisé dans le projet, combinant la construction du métamodèle par krigeage (Annexe 1), l'enrichissement séquentiel par le critère d'Expected Improvement, et la parallélisation par Constant Liar.

8.1 Algorithme principal

Définition 8.1.1 (Algorithme EGO pour l'optimisation d'itinéraire)**.**
Entrées :
- Graphe $G = (V, E)$ discrétisant Ω_{free}
- Points de départ $\mathbf{x}_A$ et d'arrivée $\mathbf{x}_B$
- Nombre de points initiaux n_0, nombre de processeurs q
- Seuil de convergence $\varepsilon > 0$, budget maximal $N_{\max}$

Sortie : Chemin optimal γ^* de $\mathbf{x}_A$ à $\mathbf{x}_B$ minimisant le risque.

Phase 1 — Plan d'expériences initial

1. Sélectionner $\mathbf{X}_0 = \{\mathbf{x}_1, \ldots, \mathbf{x}_{n_0}\} \subset V$ par *Farthest Point Sampling* (cf. section 3.2.2).
2. Évaluer le coût par simulation physique en chaque point : $\mathbf{Y}_0 = (f(\mathbf{x}_1), \ldots, f(\mathbf{x}_{n_0}))^\top$.
3. Poser $n \leftarrow n_0$.

Phase 2 — Boucle d'enrichissement séquentiel

4. **Tant que** $n < N_{\max}$:
   (a) **Ajustement du krigeage :** Estimer les hyperparamètres $\hat{\boldsymbol{\theta}}$ par maximum de vraisemblance (Annexe 1, éq. (7.7)). Calculer $m_n(\mathbf{x})$ et $s_n^2(\mathbf{x})$ sur l'ensemble des nœuds de V (Annexe 1, éq. (7.5), (7.6)).
   (b) **Test de convergence :** Calculer $\text{EI}_{\max} = \max_{\mathbf{x} \in V} \text{EI}(\mathbf{x})$.
   Si $\text{EI}_{\max} < \varepsilon$, **sortir** de la boucle.
   (c) **Sélection de q points par Constant Liar :**
      i. Poser $\mathbf{X}_{\text{CL}} \leftarrow \mathbf{X}_n$, $\mathbf{Y}_{\text{CL}} \leftarrow \mathbf{Y}_n$.
      ii. **Pour** $j = 1, \ldots, q$:
         - Calculer le critère EI sur V avec le plan $(\mathbf{X}_{\text{CL}}, \mathbf{Y}_{\text{CL}})$ (Annexe 1, éq. (7.12)).
         - $\mathbf{x}_{n+j} \leftarrow \arg\max_{\mathbf{x} \in V} \text{EI}(\mathbf{x})$.
         - $\mathbf{X}_{\text{CL}} \leftarrow \mathbf{X}_{\text{CL}} \cup \{\mathbf{x}_{n+j}\}, \quad \mathbf{Y}_{\text{CL}} \leftarrow \mathbf{Y}_{\text{CL}} \cup \{L\}$.
      iii. Fin Pour.
   (d) **Évaluations parallèles :** Exécuter les q simulations physiques en parallèle :
   $f(\mathbf{x}_{n+1}), \ldots, f(\mathbf{x}_{n+q})$.
   (e) **Mise à jour :**
   $\mathbf{X}_n \leftarrow \mathbf{X}_n \cup \{\mathbf{x}_{n+1}, \ldots, \mathbf{x}_{n+q}\}$,
   $\mathbf{Y}_n \leftarrow \mathbf{Y}_n \cup \{f(\mathbf{x}_{n+1}), \ldots, f(\mathbf{x}_{n+q})\}$,
   $n \leftarrow n + q$.
5. Fin Tant que.

Phase 3 — Extraction du chemin optimal

6. Pondérer chaque arête $(u, v) \in E$ par le coût intégré.
7. Appliquer l'algorithme de Dijkstra sur G pondéré pour obtenir $\gamma^* = \text{Dijkstra}(G, \mathbf{x}_A, \mathbf{x}_B)$.
8. **Retourner** γ^*.

8.2 Complexité

La complexité de chaque itération de la boucle d'enrichissement est dominée par :

— L'inversion de la matrice de covariance $\mathbf{K}$ en $\mathcal{O}(n^3)$, nécessaire à la mise à jour du krigeage.

— L'évaluation de l'EI sur les $|V|$ nœuds du graphe en $\mathcal{O}(n^2|V|)$.

— Les q simulations physiques, exécutées en parallèle et donc de coût mural égal à celui d'une seule simulation.

Le nombre total d'itérations de la boucle est $\lceil (N_{\max} - n_0)/q \rceil$. En pratique, la convergence est atteinte bien avant $N_{\max}$ grâce à la stratégie d'enrichissement ciblé.

Bibliographie

[1] Mohamed Amine Bouhlel, John T. Hwang, Nathalie Bartoli, Rémi Lafage, Joseph Morlier, and Joaquim R. R. A. Martins. A python surrogate modeling framework with derivatives. *Advances in Engineering Software*, 135 :102662, 2019.

[2] David Ginsbourger. Krigeage et algorithmes de la famille EGO : autour du critère d'EI multipoints. Séminaire IMPEC, CEA Saclay, octobre 2009. Université de Neuchâtel, Stochastic Characterization Hydrogeology Group.

[3] Donald R. Jones. A taxonomy of global optimization methods based on response surfaces. *Journal of Global Optimization*, 21 :345–383, 2001.

[4] Donald R. Jones, Matthias Schonlau, and William J. Welch. Efficient global optimization of expensive black-box functions. *Journal of Global Optimization*, 13(4) :455–492, 1998.

[5] Julien Villemonteix. *Optimisation de fonctions coûteuses – Modèles gaussiens pour une utilisation efficace du budget d'évaluations : théorie et pratique industrielle.* Thèse de doctorat, Université Paris-Sud XI, 2008. Spécialité physique, École Doctorale STITS.